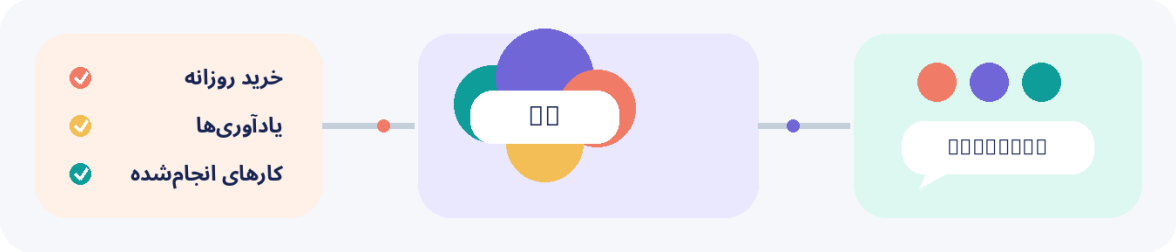
hermes-mini

مستندات فنی پروژهٔ درس رایانش ابری

دستیار کارهای روزانه روی تلگرام، کاملاً **serverless** روی پلن رایگان **Cloudflare**



مشخصات پروژه

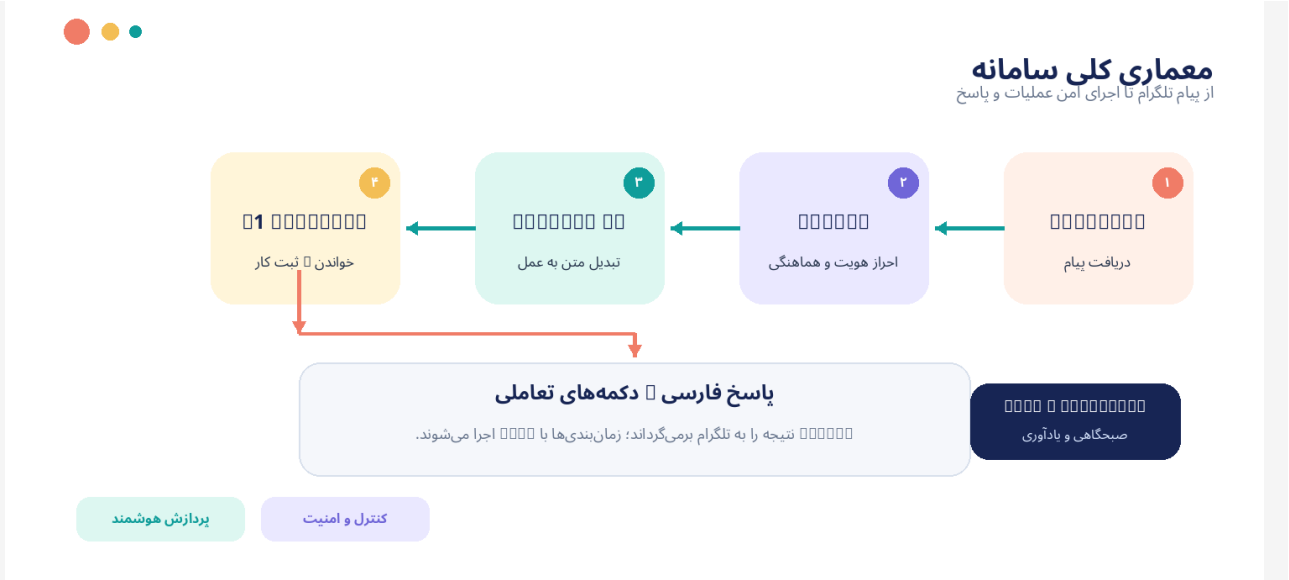
نام و نام‌خانوادگی: عطیه شمس
شماره دانشجویی: ۴۰۲۱۲۷۷۳۵۶
نام استاد حل تمرین: امیر ابرون
تاریخ: آبان ماه ۱۴۰۵ □ نوامبر ۲۰۲۶

۱. خلاصهٔ پروژه

hermes-mini یک ربات تلگرام برای ثبت، تیک‌زدن، ویرایش و حذف کارهای روزانه است. هیچ دستور اسلشی ندارد: کاربر فارسی آزاد می‌نویسد (مثلاً «شیر بخر» یا «شیر رو خریدم») و یک مدل زبانی تصمیم می‌گیرد چه عملی انجام شود. ربات به فارسی جواب می‌دهد، حالتش در پایگاه داده می‌ماند و از هر دستگاهی همان است. هیچ سرور، ماشین مجازی یا کانتینری وجود ندارد و کد فقط وقتی اجرا می‌شود که رویدادی برسد.

انتخاب	بخش
webhook با Telegram Bot API	پیام‌رسان
Cloudflare Workers، یک فایل TypeScript بدون فریم‌ورک	اجرا
Cloudflare D1 (SQLite) با migration جدا از کد	پایگاه داده
Workers AI، مدل @cf/google/gemma-4-26b-a4b-it (با متغیر AI_MODEL قابل تغییر)	مدل زبانی
Cron Triggers: پیام صبحگاهی و بررسی یادآوری‌ها	زمان‌بندی
فقط رایگان، بدون سرور یا سرویس پولی	پلن
https://hermes-mini.<subdomain>.workers.dev	آدرس زنده
https://github.com/<username>/hermes-mini	مخزن

۲. معماری

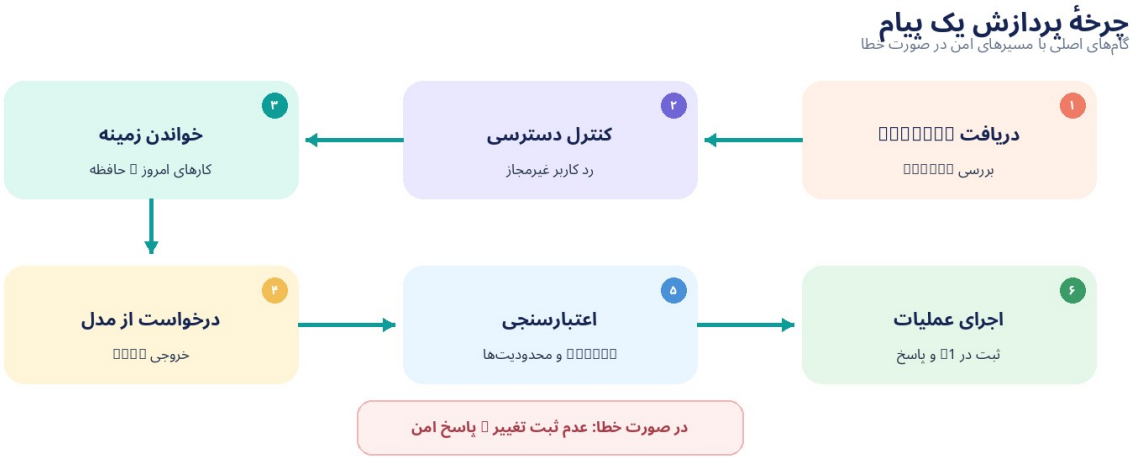


اجزا

نقش	جزء
دریافت پیام کاربر و تحویل آن با webhook؛ ارسال پاسخ	**Telegram Bot API**
احراز هویت، تشخیص عمل با مدل، اجرای عمل، پاسخ	**Worker (fetch)**
اجرای Cron: پیام صبحگاهی و یادآوری‌های ساعت‌دار	**Worker (scheduled)**

نقش	جزء
تبدیل متن آزاد فارسی به یک عمل JSON	**Workers AI**
نگهداری کارها، زمان یادآوری و حافظهٔ گفتگو	**D1**

مسیر یک پیام



1. کاربر پیام می‌فرستد و تلگرام آن را با POST به `/webhook` می‌رساند.
2. Worker هدر secret را چک می‌کند؛ اگر درست نبود 403 می‌دهد.
3. اگر فرستنده کاربر مجاز نیست، بی‌صدا رد می‌شود.
4. کارهای امروز (به وقت تهران) و چند پیام آخر از D1 خوانده می‌شود.
5. متن، لیست کارها و حافظهٔ گفتگو به مدل داده می‌شود و یک خط JSON برمی‌گردد.
6. خروجی مدل اعتبارسنجی می‌شود. اگر نامعتبر بود چیزی نوشته نمی‌شود.
7. عمل در D1 اجرا و پاسخ فارسی (با دکمه‌ها) به تلگرام فرستاده می‌شود.
8. Worker از ابتدا 200 برگردانده تا تلگرام پیام را دوباره نفرستد؛ پردازش با `ctx.waitUntil` ادامه می‌یابد.

۳. تصمیم‌های طراحی

دلیل	تصمیم	پرسش
Worker فقط با رسیدن رویداد اجرا می‌شود. polling یک فرایند همیشه‌روشن می‌خواهد که با مدل serverless نمی‌خواند.	webhook	**webhook** یا **polling**؟
بار کم و منقطع است؛ نه سرور، نه Docker، و در زمان بیکاری هزینه‌ای نیست.	Cloudflare Workers	چرا **FaaS**؟
به query (کارهای یک روز)، تجمیع (آمار) و بروزرسانی شرطی (یادآوری‌های رسیده) نیاز داریم که در SQL ساده است. KV برای این الگو مناسب نیست.	D1	چرا **D1** و نه **KV**؟
Worker بدون state است؛ کارها، یادآوری‌ها و حافظهٔ گفتگو در D1 هستند.	فقط D1	**state** کجاست؟
طبق الزام پروژه؛ منطق کوچک است و فریم‌ورک لازم نیست.	`src/index.ts`	چرا یک فایل؟
پاسخ غیر ۲۰۰ باعث ارسال مجدد پیام توسط تلگرام می‌شود.	بعد از احراز هویت	چرا همیشه 200؟

دلیل	تصمیم	پرسش
کاربر با شمارهٔ ردیف حرف می‌زند، ولی دکمه‌ها از id واقعی دیتابیس استفاده می‌کنند تا با تغییر لیست قاطی نشوند.	هر دو	شمارهٔ ردیف یا **id**؟
مدل‌ها منسوخ می‌شوند؛ با عوض کردن متغیر و دیپلوی، بدون دست‌زدن به کد عوض می‌شود.	متغیر AI_MODEL	نام مدل کجاست؟

۴. قابلیت‌ها

نتیجه	عمل	کاربر می‌گوید
کار جدید ثبت می‌شود	add	شیر بخر
کار تیک می‌خورد	done	شیر رو خریدم
تیک برداشته می‌شود	undone	تیکش رو بردار
کار حذف می‌شود	del	شماره ۲ رو پاک کن
متن کار عوض می‌شود	edit	شماره ۱ رو بکن خرید شیر کم‌چرب
لیست امروز با دکمه‌ها	list	چیه کارام
آمار ۷ روز اخیر	stats	این هفته چند تا کار انجام دادم؟
یادآوری ساعت‌دار	remind	ساعت ۵ عصر یادم بنداز به مامان زنگ بزنم
پاسخ گفتگویی با حافظهٔ کوتاه	chat	سلام

قابلیت‌های همراه:

- **دکمه‌های شیشه‌ای:** زیر لیست، برای هر کار دکمهٔ تیک یا برداشتن تیک و دکمهٔ حذف. کلیک مستقیم در D1 اعمال و همان پیام ویرایش می‌شود.
- **پیام صبحگاهی:** هر روز ساعت ۸ صبح تهران، لیست امروز و کارهای انجام‌نشدهٔ دیروز.
- **یادآوری ساعت‌دار:** در زمان مقرر پیام «یادآوری» با دکمهٔ «انجام شد» می‌رسد.
- **حافظهٔ گفتگو:** ۶ پیام آخر به مدل داده می‌شود و ۲۰ پیام نگه‌داری می‌شود.

مجموعهٔ عمل‌های پروژه شش عمل ثابت (add, done, undone, del, list, chat) بود. چهار عمل edit، stats، remind و یک عمل نمایشی دیگر در این حد اضافه نشده‌اند؛ سه عمل edit، stats و remind به آن افزوده شد و مجموعه همچنان بسته و اعتبارسنجی‌شده است.

۵. پایگاه داده

دو migration جدا از کد در پوشهٔ /migrations است و با wrangler d1 migrations apply اجرا می‌شود.

```
-- init.sql_0001
CREATE TABLE tasks (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
  text TEXT NOT NULL,
  done INTEGER NOT NULL DEFAULT 0,
  day TEXT NOT NULL,
  created_at INTEGER NOT NULL
);
CREATE INDEX idx_tasks_day ON tasks(day);

CREATE TABLE messages (
  id INTEGER PRIMARY KEY AUTOINCREMENT,
```

```
    , role TEXT NOT NULL
    , content TEXT NOT NULL
    created_at INTEGER NOT NULL
    ; (

-- reminders.sql_0002
; ALTER TABLE tasks ADD COLUMN remind_at INTEGER
; ALTER TABLE tasks ADD COLUMN reminded INTEGER NOT NULL DEFAULT 0
CREATE INDEX idx_tasks_due ON tasks(remind_at)
; WHERE reminded = 0 AND remind_at IS NOT NULL
```

کاربرد	جدول
کارها، وضعیت انجام، روزی که به آن تعلق دارند و زمان یادآوری	**tasks**
حافظهٔ گفتگو؛ فقط ۲۰ پیام آخر نگه داشته می‌شود	**messages**

تعریف «امروز» (منطقهٔ زمانی تهران)

Worker منطقهٔ زمانی ندارد و ساعتش UTC است. «امروز» با Intl.DateTimeFormat و 'timeZone: 'Asia/Tehran محاسبه و به‌صورت YYYY-MM-DD در ستون day ذخیره می‌شود. چون ایران ساعت تابستانی ندارد، اختلاف ثابت UTC+03:30 است و ۸ صبح تهران برابر ۰۴:۳۰ UTC است. هر کار به روزی تعلق دارد که برایش ثبت شده و آمار هفتگی هم بر همین اساس است. ایندکس جزئی idx_tasks_due فقط یادآوری‌های ارسال‌نشده را پوشش می‌دهد تا بررسی هر دقیقه ارزان بماند.

۶. لایهٔ هوشمند (LLM)

مدل باید فقط **یک خط JSON** برگرداند. system prompt شامل شرح عمل‌ها، قوانین، چند مثال و لیست شمارهٔ کارهای امروز و گفتگوی اخیر است.

فیلدها	عمل
text	**add**
numbers (شمارهٔ ردیف در لیست امروز)	**done, undone, del**
numbers (دقیقاً یکی) و text	**edit**
text و یکی از time (به شکل HH:MM) یا minutes	**remind**
بدون فیلد	**list, stats**
reply	**chat**

اعتبارسنجی

تابع validate خروجی مدل را با schema دستی چک می‌کند: عمل باید در مجموعهٔ مجاز باشد، متن‌ها خالی و بیش از حد بلند نباشند، شماره‌ها عدد صحیح (حداکثر ۱۰ تا) باشند، ساعت با الگوی ۰۰:۰۰ تا ۲۳:۵۹ بخواند و دقیقه بین ۱ تا ۱۴۴۰ باشد. ارقام فارسی به لاتین تبدیل می‌شوند. فقط اولین {...} از خروجی استخراج می‌شود تا متن اضافه مشکل نسازد.

مسیرهای امن در خطا

رفتار	وضعیت
هیچ چیزی نوشته نمی‌شود؛ پاسخ «متوجه نشدم»	خروجی نامعتبر یا خطای مدل
هیچ عملی انجام نمی‌شود؛ لیست نشان داده می‌شود	شمارهٔ خارج از لیست (حتی یکی از چند شماره)

رفتار	وضعیت
چیزی پاک نمی‌شود؛ شمارهٔ دقیق می‌خواهد	«همه رو پاک کن»
سؤال برمی‌گرداند	پیام مبهم («اون یکی رو انجام دادم»)
می‌پرسد صبح یا عصر	«ساعت ۵ یادم بنداز»
برای فردا ثبت می‌شود	ساعت یادآوری گذشته

پیام کاربر در prompt فقط «درخواست» حساب می‌شود، نه دستور جدید برای مدل. رفتار دقیق پیام‌های چالشی به مدل وابسته است، ولی اعتبارسنجی و مسیرهای امن بدون توجه به خروجی مدل جلوی نوشتن دادهٔ بد را می‌گیرد.

۷. امنیت

پیاده‌سازی	الزام
مقایسهٔ from.id با ALLOWED_TELEGRAM_ID؛ پیام و کلیک دکمهٔ دیگران بی‌صدا رد می‌شود	فقط کاربر مجاز
هدر x-telegram-bot-api-secret-token؛ بدون آن پاسخ 403	**webhook** با **secret**
TELEGRAM_BOT_TOKEN و TELEGRAM_WEBHOOK_SECRET فقط با wrangler secret put در secret store ثبت شده‌اند	مدیریت **secret**
.gitignore شامل .dev.vars, .wrangler, node_modules؛ فقط vars مقدار غیرمحرمانه دارد	مخزن بدون **secret**
/run-reminder با همان secret محافظت می‌شود	**endpoint** تست

اگر توکنی لو برود، باید در BotFather با /revoke باطل و دوباره با wrangler secret put ثبت شود.

۸. یادآوری‌ها و Cron

کار	زمان	Cron
پیام صبحگاهی	هر روز ۰۴:۳۰ UTC (۸ صبح تهران)	30 4 * * *
ارسال یادآوری‌های ساعت‌دارِ رسیده	هر دقیقه	* * * * *

در هر اجرای دقیقه‌ای، یادآوری‌هایی که remind_at آن‌ها گذشته و reminded = 0 است پیدا می‌شوند. هر مورد قبل از ارسال با UPDATE ... WHERE reminded = 0 علامت می‌خورد تا دوبار ارسال نشود. اگر کار قبلاً انجام شده باشد پیام فرستاده نمی‌شود. دقت یادآوری حدود یک دقیقه است. برای نمایش زنده، POST /run-reminder همان پیام صبحگاهی را فوراً اجرا می‌کند.

۹. استقرار و عملیات

```
npm install
npx wrangler login
npx wrangler d1 create hermes-mini
npx wrangler d1 migrations apply hermes-mini --remote
npx wrangler secret put TELEGRAM_BOT_TOKEN
npx wrangler secret put TELEGRAM_WEBHOOK_SECRET
npx wrangler deploy
```

ثبت webhook:

```
curl -X POST "https://api.telegram.org/bot<TOKEN>/setWebhook" \
  -d "url=https://hermes-mini.<subdomain>.workers.dev/webhook" \
  -d "secret_token=<WEBHOOK_SECRET>"
```

بررسی	انتظار
GET /health	ok
POST /webhook بدون هدر	403
npx wrangler tail	لاگ زنده هر درخواست در دمو
getWebhookInfo	آدرس درست و بدون last_error_message

Observability در wrangler.jsonc فعال است. ترتیب مهم: اول migration، بعد دیپلوی کد جدید.

۱۰. تحلیل هزینه

فرض‌ها (تخمینی): هر کاربر روزی ۵۰ پیام می‌فرستد؛ هر پیام یک بار مدل را صدا می‌زند؛ prompt حدود ۱٬۵۰۰ توکن ورودی و پاسخ حدود ۵۰ توکن خروجی دارد.

معیار	۱ کاربر	۱۰٬۰۰۰ کاربر
درخواست **Worker** در روز	حدود ۱٬۵۰۰ (۵۰ پیام + ۱٬۴۴۰ کرون + ۱ صبحگاهی)	حدود ۵۰۱٬۵۰۰ (کرون تقریباً ثابت می‌ماند)
فراخوانی مدل در روز	۵۰	۵۰۰٬۰۰۰
توکن ورودی مدل در روز	حدود ۷۵ هزار	حدود ۷۵۰ میلیون
خواندن و نوشتن **D1**	چند صد سطر در روز	چند ده میلیون سطر در روز

قیمت مدل در صفحهٔ رسمی Workers AI هنگام نگارش حدود ۰٫۱۰ دلار به‌ازای هر میلیون توکن ورودی و ۰٫۳۰ دلار برای خروجی بود. با همین فرض، ۱۰٬۰۰۰ کاربر ورودی مدل را حدود ۷۵ دلار در روز و خروجی را حدود ۷ دلار در روز می‌کند؛ یعنی حدود ۲٬۵۰۰ دلار در ماه، فقط برای مدل.

> *سقف‌های دقیق پلن رایگان (تعداد درخواست Worker، خواندن و نوشتن D1، سهمیهٔ روزانهٔ Workers AI، تعداد Cron) را قبل از تحویل از صفحات Limits و Pricing همان سرویس‌ها بخوان و در این جدول بنویس؛ این مقدارها عوض می‌شوند.*

نتیجه: برای یک کاربر همه‌چیز در حد پلن رایگان است و هزینه عملاً صفر است. برای ۱۰٬۰۰۰ کاربر پلن پولی Workers لازم می‌شود و بیشترین هزینه مدل زبانی است. راه‌های کاهش: prompt کوتاه‌تر یا ذخیرهٔ بخش ثابت آن، مدل کوچک‌تر برای پیام‌های ساده، و پاسخ‌های بدون مدل برای الگوهای قطعی. معماری هم باید چندکاربره شود (ستون user_id و مجوزدهی) و یادآوری‌ها به الگویی مثل Durable Objects alarms یا Queues بروند.

۱۱. جاهایی که گیر کردم و راه‌حل

مشکل	علت	راه‌حل
خطای **npm -v running scripts is disabled** داد	اجرای اسکریپت در PowerShell ویندوز بسته بود	Set-ExecutionPolicy -Scope CurrentUser RemoteSigned

مشکل	علت	راه‌حل
curl به api.telegram.org وصل نشد	فیلترشکن فقط مرورگر را پوشش می‌داد و curl.exe پروکسی سیستم را نمی‌خواند	setWebhook از مرورگر با GET انجام شد (روش‌های دیگر: متغیر پروکسی یا حالت TUN)
ربات همیشه «متوجه نشدم» می‌گفت	مدل نمونهٔ مرجع در Workers AI منسوخ شده بود (AiError 5028)	لاگ زنده را خواندم، مدل را به Gemma 4 عوض کردم و نام آن را به متغیر AI_MODEL بردم
بعد از تغییر مدل هم جواب خالی بود	مدل جدید خروجی را در choices[0].message.content می‌دهد، نه response	تابع خواندن خروجی هر دو قالب را پشتیبانی می‌کند و max_tokens بیشتر شد
نمونهٔ مرجع دستور اسلشی داشت	الزام R1 فقط متن آزاد می‌خواهد	همهٔ دستورها حذف و تشخیص کامل به LLM سپرده شد
workers.dev در مرورگر باز نمی‌شود	فیلتر بودن دامنه از ایران	تست با curl؛ ربات از سمت Cloudflare به تلگرام وصل است و اثری نمی‌پذیرد

مهم‌ترین درس: پلتفرم‌های LLM مدل‌ها را زود منسوخ می‌کنند، پس نام مدل باید پیکربندی باشد نه کد. لاگ زنده (wrangler tail) عیب‌یابی را از حدس به خواندن خطای دقیق تبدیل کرد.

۱۲. محدودیت‌ها و ادامهٔ کار

- فقط یک کاربر پشتیبانی می‌شود (طبق الزامات پروژه).
- یادآوری فقط «امروز» یا «اولین وقوع بعدی ساعت» را می‌فهمد و تاریخ دلخواه ندارد.
- کیفیت تشخیص به مدل وابسته است؛ اعتبارسنجی فقط جلوی دادهٔ بد را می‌گیرد، نه جواب نامناسب.
- حذف از طریق دکمه تأییدیه ندارد.
- ایده‌ها برای ادامه: انتقال خودکار کارهای ناتمام، تاریخ دلخواه در یادآوری، پیام صوتی با تبدیل گفتار به متن، تأیید قبل از حذف، چندکاربره‌سازی.

۱۳. نگاشت به الزامات و فازهای پروژه

چگونه	وضعیت	الزام
بدون دستور اسلشی	انجام شد	**R1** متن آزاد فارسی
add, done, undone, del, list, chat به‌علاوهٔ edit, stats, remind	انجام شد	**R2** عمل از مجموعهٔ ثابت
validate و بازگشت «متوجه نشدم»	انجام شد	**R3 JSON** اعتبارسنجی‌شده با مسیر امن
جدول messages	انجام شد	**R4** حافظهٔ گفتگو
ALLOWED_TELEGRAM_ID	انجام شد	**R5** کاربر مجاز
بدون هدر 403	انجام شد	**R6 webhook** با **secret**
/migrations	انجام شد	**R7 D1** با **migration** جدا
Workers، D1، Workers AI	انجام شد	**R8** فقط پلن رایگان
Cron Triggers	انجام شد	بونوس: یادآوری

محتوا در این سند	فاز
بخش‌های ۲ و ۳	۱ طراحی
بخش‌های ۲ و ۷	۲ **Worker** و **webhook** امن
بخش ۵	۳ **D1**
بخش ۶	۴ لایهٔ هوشمند
بخش ۹	۵ عملیات
بخش‌های ۱۰ و ۱۱	۶ گزارش

۱۴. سناریوی نمایش (دمو)

1. `curl $BASE/health` ← ok؛ POST /webhook بدون هدر ← 403.
2. `npx wrangler secret list` برای نشان دادن اینکه secretها فقط در secret store هستند.
3. در تلگرام: سلام، شیر بخر، نان بخر، زنگ بزنم به مامان.
4. ۱ دقیقه دیگه یادم بنداز آب بخورم (تا پایان نمایش می‌رسد).
5. چیه کارام، شیر رو خریدم، شماره ۲ رو بکن خرید نان بربری، کلیک روی دکمه‌ها.
6. پیام‌های چالشی: شماره ۹ رو پاک کن، همه رو پاک کن، اون یکی رو انجام دادم، ساعت ۵ یادم بنداز.
7. این هفته چند تا کار انجام دادم؟.
8. اجرای دستی POST /run-reminder و نمایش پیام صبحگاهی.
9. نمایش `wrangler tail` و مخزن GitHub بدون secret.