hermes-mini

ربات تلگرامی مدیریت کارهای روزانه روی Cloudflare Workers

مستندات پروژهٔ درس رایانش ابری

معماری بدون سرور · پایگاه دادهٔ D1 · مدل زبانی Workers AI

Serverless Cloudflare D1 Telegram Webhook LLM Structured Output

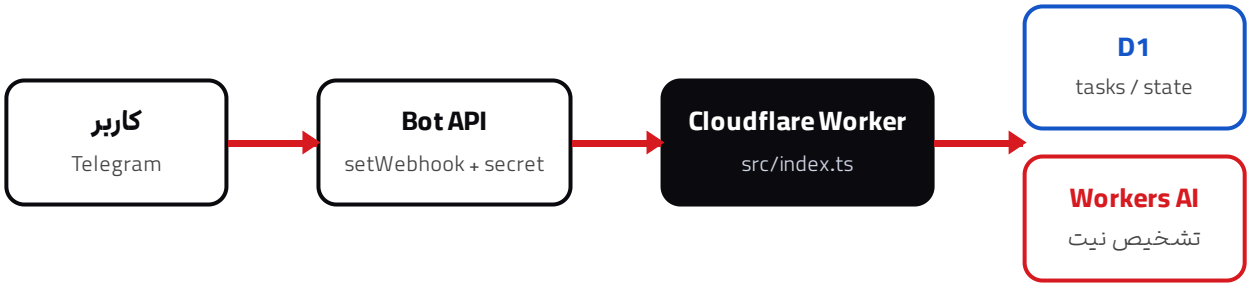
این سند بر اساس کد پروژه و تصمیم‌های گرفته‌شده در مسیر پیاده‌سازی نوشته شده است. هیچ توکن یا secret ای در آن وجود ندارد.

۱. معرفی و هدف

hermes-mini یک ربات تلگرام است که کارهای روزانه را ثبت می‌کند، تیک می‌زند، حذف می‌کند و فهرست می‌دهد. کاربر فارسی و آزاد می‌نویسد؛ تشخیص نیت پیام و انتخاب عمل بر عهدهٔ مدل زبانی است. کل سیستم روی طرح رایگان Cloudflare اجرا می‌شود و هیچ سرور شخصی‌ای ندارد.

پیام کاربر	رفتار ربات
خرید شیر	یک کار جدید ثبت می‌شود و در صورت نبودن ساعت، ساعتش پرسیده می‌شود.
شیر رو خریدم	کار مربوطه تیک می‌خورد.
زنگ مامان هنوز مونده	تیک کار برداشته می‌شود و دوباره انجام‌نشده می‌شود.
شماره ۲ رو پاک کن	کار شمارهٔ ۲ حذف می‌شود.
همه رو حذف کن	ابتدا تأیید می‌گیرد؛ فقط با «بله» همهٔ کارهای امروز حذف می‌شود.
کدوم کارام تکراریه؟	کارهای هم‌متن، با تعداد تکرار و شمارهٔ امروزشان فهرست می‌شوند.
سلام	پاسخ گفت‌وگویی.

۲. معماری نهایی



مسیر پیام از کاربر تا Worker و از Worker به D1 و مدل زبانی؛ پاسخ با sendMessage برمی‌گردد.

تصمیم‌های طراحی

پرسش	انتخاب	دلیل
Webhook یا Polling؟	**Webhook**	سرور همیشه‌روشن نداریم. تلگرام فقط هنگام ورود پیام Worker را صدا می‌زند و هزینه و پیچیدگی نگه‌داری صفر است.
چرا FaaS؟	**Workers**	بار کار کم و رویدادمحور است؛ کد فقط وقتی اجرا می‌شود که پیام یا cron برسد.
D1 یا KV؟	**D1 (SQL)**	کارها رابطه‌ای‌اند و به پرس‌وجو بر اساس روز و کاربر، به‌روزرسانی و حذف بر اساس شناسه نیاز داریم. KV جست‌وجوی ساختاریافته ندارد.
وضعیت کجا ذخیره می‌شود؟	**D1**	Worker بدون حالت (stateless) است. حتی حالت‌های موقت، مثل «منتظر پاسخ ساعت» و «منتظر تأیید حذف»، در جدول state ذخیره می‌شوند.

۳. نگاشت الزامات

کد	الزام	وضعیت	توضیح
R1	متن آزاد فارسی، بدون دستور	**جزئی**	همهٔ عمل‌ها از متن آزاد کار می‌کنند، اما میانبرهای slash هنوز در کد باقی‌اند و باید حذف شوند.
R2	متن آزاد، تصمیم مدل، یک عمل از مجموعهٔ ثابت	**انجام**	عمل‌ها: add, done, undone, del, delall, duplicates, list, search, settime, chat.
R3	خروجی JSON معتبر و مسیر امن	**انجام**	اعتبارسنجی عمل، شماره‌ها و فیلدها؛ خروجی خراب فقط یک پیام امن می‌دهد و چیزی نمی‌نویسد.
R4	حافظهٔ گفت‌وگو	**جزئی**	حافظهٔ کوتاه برای پرسش ساعت و تأیید حذف دارد؛ حافظهٔ چندپیامی چت هنوز پیاده نشده است.
R5	محدودیت دسترسی با ID	**انجام**	فهرست ID مجاز در متغیر کانفیگ؛ فرستندهٔ غیرمجاز بی‌صدا نادیده گرفته می‌شود.
R6	secret با webhook	**انجام**	هر درخواست بدون هدر درست، پاسخ ۴۰۳ می‌گیرد.
R7	D1 و migration جدا از کد	**انجام**	سه فایل SQL در پوشهٔ migrations.
R8	فقط طرح رایگان	**انجام**	فقط D1، Workers و Workers AI.

۴. ساختار پروژه و پایگاه داده

```
hermes-mini/
  src/index.ts              # all Worker logic (single file)
  migrations/
    0001_init.sql           # tasks table
    0002_state_time.sql     # time, reminded, state, messages
    0003_user_id.sql        # per-user task lists
  wrangler.jsonc            # bindings, vars, cron
```

جدول `tasks` کارها را نگه می‌دارد و جدول `state` حالت‌های موقت را به‌صورت کلید و مقدار. کلید هر حالت با شناسهٔ کاربر ساخته می‌شود تا حالت یک نفر روی دیگری اثر نگذارد.

```
ALTER TABLE tasks ADD COLUMN user_id TEXT;
CREATE INDEX idx_tasks_user_day ON tasks(user_id, day);
CREATE TABLE state (k TEXT PRIMARY KEY, v TEXT NOT NULL);
```

تعریف «امروز» (زمان تهران): سرور Cloudflare منطقهٔ زمانی ندارد و زمان‌ها UTC هستند. «امروز» در کد با `Intl.DateTimeFormat` و منطقهٔ `Asia/Tehran` محاسبه می‌شود. تهران UTC+3:30 ثابت است، چون ساعت تابستانی لغو شده است. پیام صبحگاهی و روز هر کار هم بر همین پایه است.

۵. جریان پردازش پیام

1. تلگرام درخواست `POST /webhook` را می‌فرستد.
2. هدر `X-Telegram-Bot-Api-Secret-Token` با secret مقایسه می‌شود؛ اگر نخورد، پاسخ **۴۰۳** است.
3. فرستنده با فهرست ID مجاز چک می‌شود؛ غیرمجاز بی‌صدا رد می‌شود.
4. اگر منتظر پاسخ ساعت یا تأیید حذف باشیم، همان پردازش می‌شود.
5. در غیر این صورت متن و فهرست کارهای امروز به مدل داده می‌شود و یک خط JSON برمی‌گردد.
6. خروجی اعتبارسنجی می‌شود و عمل مناسب روی D1 اجرا و پاسخ فارسی ارسال می‌شود.
7. در هر حالتی، حتی خطا، پاسخ **۲۰۰** برمی‌گردد تا تلگرام پیام را دوباره نفرستد.

۶. لایهٔ هوش مصنوعی

مدل باید فقط یک خط JSON برگرداند. چند نمونه از قرارداد خروجی:

```
{"action":"add","tasks":[{"text":"خرید شیر","time":null}]}
{"action":"del","numbers":[1,3]}
{"action":"delall"}
{"action":"duplicates"}
```

اعتبارسنجی و مسیر امن

- خروجی مدل تجزیه می‌شود و **عمل** باید در فهرست مجاز باشد.
- شمارهٔ بیرون از لیست نادیده گرفته می‌شود و در صورت پیدا نشدن هدف، پیام راهنما می‌آید.
- خطای مدل یا JSON خراب: فقط یک پیام امن و **بدون هیچ نوشتن در پایگاه داده**.
- حذف همه: لیست نشان داده می‌شود و فقط پاسخ «بله» در ۱۰ دقیقه حذف را انجام می‌دهد؛ «نه» یا هر پیام دیگر لغو است.
- اگر عبارت مبهم باشد (مثل «حذفش کن» بدون اشاره)، ربات می‌پرسد کدام کار.

کارهای تکراری

متن هر کار نرمال می‌شود (ارقام، فاصله و نیم‌فاصله) و کارهای هم‌کلید گروه‌بندی می‌شوند. هنگام ثبت، اگر همان کار امروز وجود داشته باشد، کنارش نشانهٔ تکراری می‌آید.

۷. چند کاربره

ستون `user_id` لیست هر کاربر را جدا می‌کند. شناسهٔ کاربر هر درخواست در `env.UID` قرار می‌گیرد و ثبت، فهرست، جست‌وجو، تکراری‌ها و پیام صبح فقط روی کارهای همان کاربر کار می‌کنند. یادآوری ساعت‌دار هم فقط به صاحب همان کار ارسال می‌شود.

> **یادآوری:** صورت پروژه «دقیقاً یک کاربر» را می‌خواهد. قابلیت چندکاربره افزونه‌ای است که باید در گزارش توجیه شود.

۸. راه‌اندازی و استقرار

```
npm install
npx wrangler login
npx wrangler d1 create hermes-mini
npx wrangler d1 migrations apply hermes-mini --remote
npx wrangler secret put TELEGRAM_BOT_TOKEN
npx wrangler secret put TELEGRAM_WEBHOOK_SECRET
npx wrangler deploy
```

اتصال webhook (به‌جای مقادیر داخل < > مقدار واقعی را بگذارید و هرگز در ریپو ننویسید):

```
curl "https://api.telegram.org/bot<TOKEN>/setWebhook" \
  -d "url=https://<worker>.workers.dev/webhook" \
  -d "secret_token=<SECRET>"
```

برای لاگ زنده در دمو: `npx wrangler tail` . سلامت سرویس هم با `curl` روی آدرس اصلی Worker بررسی می‌شود.

۹. عیب‌یابی

نشانه	علت و راه‌حل
خطای deploy با کد 10405	ساب‌دامین workers.dev ساخته نشده؛ یک بار وارد Workers & Pages در داشبورد شوید.
ربات ساکت است و لاگی نمی‌آید	مشکل بالادست Worker است؛ تنظیمات Zero Trust و Access را در داشبورد بررسی کنید.
مرورگر آدرس را باز نمی‌کند	workers.dev از ایران فیلتر است؛ با curl یا VPN تست کنید.
پیام تکراری می‌رسد	پاسخ HTTP باید همیشه ۲۰۰ باشد.
wrangler با fetch failed خطا می‌دهد	VPN ترمینال را روی حالت TUN یا Global بگذارید یا HTTPS_PROXY را تنظیم کنید.

۱۰. هزینه و محدودیت‌ها

سقف‌های رایگان، طبق مستندات Cloudflare در زمان نگارش، باید پیش از تحویل دوباره تطبیق داده شوند.

مقیاس	تحلیل
۱ کاربر	چند ده تا چند صد درخواست در روز؛ بسیار کمتر از سقف رایگان Workers و D1. محدودکننده‌ترین بخش سهمیهٔ روزانهٔ Workers AI است و مدل بزرگ آن را سریع‌تر مصرف می‌کند. cron هر دقیقه حدود ۱۴۴۰ اجرا در روز می‌سازد که بهتر است به هر ۱۵ دقیقه کم شود.
۱۰,۰۰۰ کاربر	طرح رایگان کافی نیست: درخواست‌های روزانه، خواندن و نوشتن D1 و سهمیهٔ مدل زبانی از سقف می‌گذرند. باید به طرح پولی Workers رفت و مدل کوچک‌تر یا کش را برای کاهش هزینه به کار برد. جداسازی بر پایهٔ user_id از پیش آماده است.

محدودیت‌های شناخته‌شده

- میانبرهای slash باید برای رعایت R1 حذف شوند.
- حافظهٔ چندپیامی گفت‌وگو (R4) هنوز پیاده نشده است.
- پیام تکراری تلگرام با ذخیرهٔ update_id هنوز فیلتر نمی‌شود.