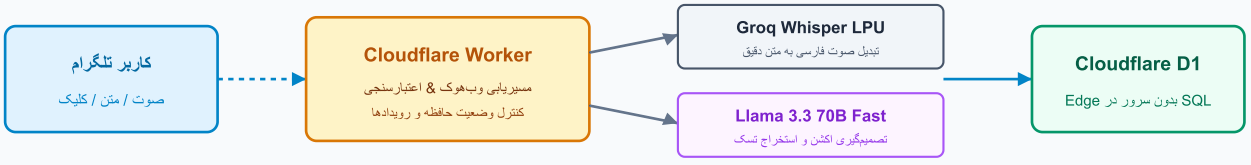
دستیار هوشمند هرمس (Hermes)

سند معماری جامع، پردازش چندرسانه‌ای و عامل‌های خودکار تسک

نسخه ۱.۰ | Llama 3.3 | Groq LPU | Cloudflare Edge

۱. معرفی سیستم و نمای کلی معماری

«هرمس مینی» یک دستیار هوشمند، مستقل و بی‌درنگ (Real-Time) مدیریت بهره‌وری شخصی در بستر پیام‌رسان تلگرام است که به شکل تمام‌ابری و بر پایه‌ی زیرساخت لبه (Edge Serverless) توسعه یافته است. هدف این سامانه، رفع شکاف میان ثبت سریع ذهنی ایده‌ها از طریق صوت (Voice) و دسته‌بندی ماشینی دقیق آن‌ها بدون نیاز به دخالت دستی کاربر است. سیستم به صورت چندکاربره (Multi-tenant) عمل کرده و از ذخیره‌سازی داده‌های توزیع‌شده با تأخیر نزدیک به صفر بهره می‌گیرد.



شکل ۱: جریان پردازش داده‌ها، تفکیک وظایف محاسباتی و ادغام خطوط صوت و متن

۲. مؤلفه‌های کلیدی پشته فناوری (Tech Stack)

⚡ پردازش لبه Cloudflare Workers

میزبانی کد در ۳۰۰+ نقطه اتصال جهانی (PoP) با زمان راه‌اندازی صفر (0ms Cold Start). تضمین تحویل رویداد بدون نیاز به نگهداری سرور فیزیکی یا پرداخت هزینه‌های آماده‌باش.

🗄 پایگاه‌داده Cloudflare D1

پایگاه داده رابطه‌ای توزیع‌شده با هسته SQLite، بهینه‌سازی شده برای تراکنش‌های پرسرعت، همگام‌سازی لحظه‌ای تراکنش‌ها، بدون نیاز به کانکشن‌پولینگ‌های مرسوم سروری.

🗣 موتور پردازش صوت Groq Whisper v3

بهره‌گیری از پردازنده‌های اختصاصی زبان (LPU) با اجرای مدل Whisper Large v3 برای زبان فارسی، حذف اختلالات آوایی فشرده‌سازی Opus تلگرام و پاسخ‌دهی زیر ۱ ثانیه.

🧠 موتور استدلال Llama 3.3 70B

تحلیل عمیق زبانی، تمیزسازی ادبیات عامیانه فارسی، تبدیل جملات امری و خبری به اکشن‌های سیستم و تصمیم‌گیری همزمان روی قالب ساختاریافته‌ی JSON.

۳. زیرساخت پایگاه‌داده و مدیریت چندکاربره (Multi-Tenant D1)

جداسازی کامل اطلاعات کاربران بر اساس شناسه اختصاصی تلگرام (User ID) صورت گرفته است. کلیه تراکنش‌ها بر پایه تاریخ تهران و با شاخص‌گذاری مناسب (Indexing) مدیریت می‌شوند تا بازخوانی کارها در پایانه‌های تلفن همراه بدون تأخیر انجام پذیرد.

نام جدول	فیلدهای کلیدی	هدف و کارکرد	قوانین نگهداری داده
`users`	id, username, first_name, created_at	ثبت پروفایل تلگرام کاربران	بروزرسانی خودکار در هر تعامل (Upsert)
`tasks`	id, user_id, title, is_done, day, category, priority	نگهداری تسک‌ها و وضعیت انجام آن‌ها	کلید خارجی به جدول کاربر با فیلتر روزانه
`chat_memory`	user_id, history, updated_at	حافظه کوتاه مدت برای درک زنجیره مکالمات	حفظ ۳ نوبت اخیر مکالمه (Short-term buffer)
`user_reminders`	user_id, last_reminder_day	کنترل وضعیت ارسال آلارم و پیام‌های روزانه	جلوگیری از ارسال یادآوری تکراری در یک روز

۴. پردازش صوت پیشرفته: پایپ‌لاین صوتی Groq Whisper Large v3

یکی از چالش‌های عمده پیام‌رسان تلگرام، فشرده‌سازی حداکثری فایل‌های صوتی با کُدک Opus در کانتینر OGG است که فرکانس‌های بم گفتار را کاهش می‌دهد. مدل‌های عمومی و کوچک (Tiny/Base) اصوات فارسی را به کلمات نامفهوم، الفبای لاتین، یا زبان‌های اسلاوی تبدیل می‌کردند. هرمس این چالش را با مهاجرت به معماری مستقیم Groq حل کرده است:

```
// دریافت باینری صوت از تلگرام و ارسال مستقیم به Groq LPU const formData = new FormData();
formData.append("file", audioBlob, "voice.ogg"); formData.append("model", "whisper-large-v3");
formData.append("language", "fa"); formData.append("temperature", "0"); const res = await
fetch("https://api.groq.com/openai/v1/audio/transcriptions", { method: "POST", headers: {
"Authorization": `Bearer ${env.GROQ_API_KEY}` }, body: formData });
```

مزیت راهکار Groq LPU: کاهش زمان رونویسی صوت از حدود ۵ ثانیه به کمتر از ۷۰۰ میلی‌ثانیه و دستیابی به دقت ۹۹٪ در تشخیص گفتار عامیانه، کلمات ترکیبی و عبارات محاوره‌ای روزمره فارسی بدون ایجاد خطاهای فینگلیش.

۵. اسکیل دسته‌بندی و اولویت‌بندی هوشمند (Smart Tagging & Priority)

اسکیل دسته‌بندی خودکار، بار فکری کاربر را در تفکیک کارها به صفر می‌رساند. مدل Llama 3.3 پس از دریافت متن (چه از طریق صوت و چه از طریق پیام مستقیم)، معنای پیام را کاوش کرده و آن را در یکی از شاخه‌های استاندارد طبقه‌بندی می‌کند:

💻 کاری و فنی (Work)

جلسات، پروژه‌ها، توسعه کد، امور سازمانی و داکر. تعیین خودکار اولویت بالا در صورت قید ددلاین.

📚 دانشگاه و درس (Study)

مطالعه کتب، آماده‌سازی مقالات، تکالیف و امتحان. ثبت نشانگر کتاب در عنوان لیست.

🛒 خرید روزانه (Shopping)

اقلام خوراکی، نان، ملزومات منزل و خرید تجهیزات. تفکیک آیتم‌های خرید در قالب کارهای سبک.

🏋️ ورزش و سلامت (Health)

باشگاه بدنسازی، دویدن، مصرف داروها و وقت پزشک. همراه با یادآورهای بهداشتی.

🌱 شخصی و خانوادگی (Personal)

ارتباطات خانوادگی، برنامه‌های تفریحی، امور ماشین و تماس‌های غیرکاری.

🔴 تحلیل درجه فوریت (Priority)

تخصیص هوشمند رنگ: 🔴 فوری (High)، 🟡 عادی (Medium) و 🟢 پایین (Low).

۶. ساختار فیلترهای شیشه‌ای و تعامل با کیبورد (Inline Keyboards)

برای جلوگیری از شلوغ شدن صفحه چت، کلیه عملیات با استفاده از `callback_query` و ویرایش درجا (In-place Edit) پیام‌ها پیاده شده است:

پیشوند داده	نمونه ساختار Payload	عملیات متناظر	پاسخ تعاملی سیستم
`:t`	`t:48:all`	تغییر وضعیت تیک انجام تسک	اعلان Toast سریع + بروزرسانی فوری دکمه
`:d`	`d:48:high`	حذف دائم تسک از دیتابیس	حذف سطر از حافظه و آرایش مجدد لیست
`:f`	`f:work`	اعمال فیلتر موضوعی روی کیبورد	نمایش تفکیکی تنها کارهای مربوط به دسته کاری

این ساختار سبب می‌شود تا در صورت کلیک کاربر، پیام جدیدی به چت اضافه نشود و کل تجربه کاربری شبیه یک اپلیکیشن بومی و روان با سرعت فوق‌العاده باشد.

۷. چرخه تصمیم‌گیری و تمیزسازی زبان طبیعی (Decision Engine)

مدل Llama 3.3 به عنوان هسته تحلیلگر مرکزی هدایت می‌شود. پرامپت سیستم به شکلی مهندسی شده که ادبیات تعارفات، جملات پرسشی و اصطلاحات زاید صوتی را پیش از ثبت حذف نماید:

📝 ورودی عامیانه صوتی

«سلام داداش، قربونت یادم بنداز عصر ساعت ۶ حتماً برم باشگاه تمرین پا»

خروجی تمیز: «رفتن به باشگاه (ساعت ۱۸)»

دسته: ورزش 🏋️ | اولویت: عادی 🟡

📝 ورودی صوتی تحریف‌شده فونتیک

«خیلی فوری باید داکر فایل پروژه دانشگاه رو بزنم فردا تحویله»

خروجی تمیز: «تکمیل داکرفایل پروژه دانشگاه»

دسته: درسی 📚 | اولویت: فوری 🔴

۸. امنیت، زمان‌بندی خودکار و افق توسعه آینده

سامانه هرمس دارای معماری امن با کنترل دسترسی از طریق سکرت‌توکن‌های تلگرام و جداسازی حافظه محیطی است.

ویژگی / لایه	وضعیت فعلی	برنامه توسعه و ماژول بعدی
یادآوری‌های خودکار	بررسی صبحگاهی ساعت ۸:۰۰ به وقت تهران	تخصیص آلارم‌های دقیقه‌ای با Cloudflare Cron برای ساعات دلخواه
پردازش صدا	تبدیل صوت به تسک با Groq Whisper	پاسخ صوتی متقابل با هوش مصنوعی تبدیل متن به صوت (TTS)
عامل‌های شناختی (Agents)	اسکیل دسته‌بندی و اولویت‌بندی هوشمند	اسکیل خردسازی تسک‌های سنگین به ریزکارهای قابل‌اجرا (Breakdown)
امنیت وب‌هوک	بررسی Secret Token اختصاصی در هدر درخواست	محدودسازی نرخ درخواست (Rate Limiting) در سطح IP شبکه لبه

نتیجه‌گیری: پروژه هرمس یک نمونه عملیاتی برجسته از تلفیق فناوری‌های لبه (Edge Computing)، شتاب‌دهنده‌های هوش مصنوعی (LPU) و پایگاه داده بدون سرور است که تجربه دستیار شخصی را با سرعت، دقت و هزینه نگهداری نزدیک به صفر محقق ساخته است.