گزارش تحلیلی پروژه رایانش ابری · فاز ششم

هرمس مینی

طراحی و تحلیل یک دستیار تلگرامی فارسی برای مدیریت هوشمند وظایف روزانه، بر پایهٔ معماری Serverless در Cloudflare

CLOUDFLARE WORKERS · D1 · WORKERS AI · TELEGRAM

مشخصات دانشجو و پروژه

اطلاعات گزارش

نام	**حسین**
نام خانوادگی	**دانش**
کد دانشجویی	**4021277196**
استاد حل تمرین	**امیر آبرون**
عنوان درس	رایانش ابری
نام پروژه	Hermes Mini - دستیار وظایف تلگرامی

۱ · مسئله و راهکار

معرفی پروژه و قابلیت‌های اصلی

هرمس مینی یک دستیار شخصی فارسی در پیام‌رسان تلگرام است که کاربر می‌تواند بدون استفاده از دستورهای ازپیش‌تعریف‌شده، کارهای روزانه‌اش را با زبان طبیعی ثبت و مدیریت کند. پیام‌هایی مانند «شیر بخر»، «شیر رو خریدم» یا «کارام چیه؟» به‌ترتیب به ثبت وظیفه، انجام‌شده‌کردن آن و نمایش فهرست تبدیل می‌شوند. هدف پروژه، ترکیب چند مفهوم رایانش ابری در یک محصول کوچک و قابل استقرار است: اجرای رویدادمحور، پایگاه‌دادهٔ ابری، وب‌هوک امن و پردازش زبان طبیعی.

۲۰

ردیف حافظه

حداکثر ۲۰ ردیف آخر مکالمه برای هر کاربر نگهداری می‌شود؛ ۱۲ ردیف اخیر به مدل داده می‌شود.

۶

عمل اصلی

مدل زبانی هر پیام را به یکی از شش کنش مشخص تبدیل می‌کند؛ تصمیم مدل مستقیماً به پایگاه‌داده دسترسی ندارد.

کنش‌های قابل تشخیص

کنش	رفتار سامانه
add	ثبت کار جدید برای امروز؛ اگر کاربر صریحاً «فردا» بگوید، تاریخ فردا ثبت می‌شود.
done	تغییر وضعیت کار مشخص به انجام‌شده و ثبت زمان تکمیل.
undone	بازگرداندن کار انجام‌شده به وضعیت انجام‌نشده.
del	حذف یک کار مشخص؛ حذف همهٔ کارها به تأیید جداگانه نیاز دارد.
list	نمایش کارهای باز امروز، کارهای انجام‌شدهٔ امروز و وظایف عقب‌افتاده.
chat	پاسخ مکالمه‌ای به سلام، تشکر، پرسش یا پیام غیرمرتبط با مدیریت وظایف.

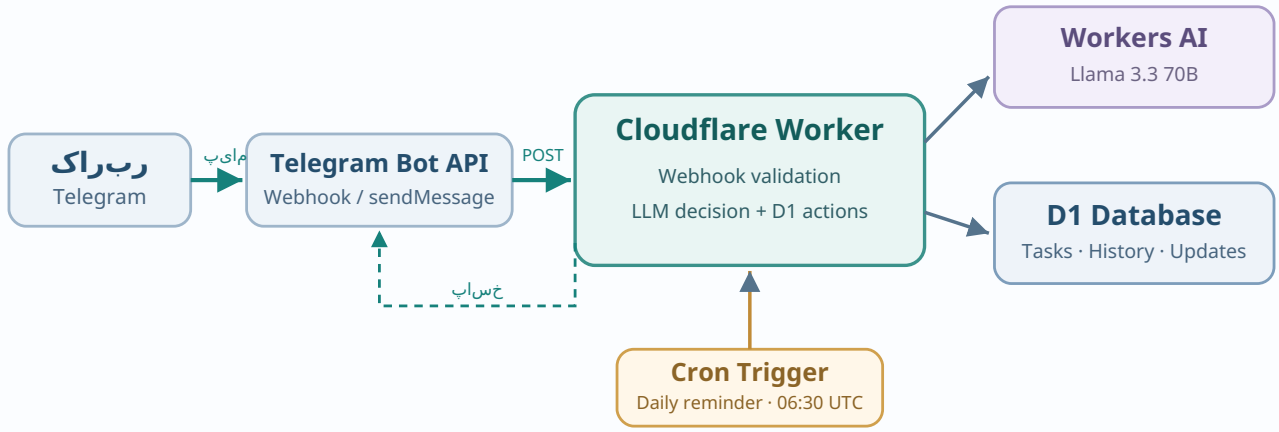
انطباق با الزامات صورت‌مسئله

کد پروژه با الزام تعامل آزاد فارسی و نبود دستورهای اسلش هماهنگ است. خروجی مدل باید JSON ساختاریافته باشد و پیش از اجرا اعتبارسنجی می‌شود. حافظهٔ کوتاه مکالمه، محدودسازی به یک شناسهٔ مجاز تلگرام، بررسی توکن محرمانهٔ وب‌هوک و ذخیره‌سازی پایدار در D1 نیز در کد وجود دارند. فایل مهاجرت پایگاه‌داده از فایل Worker جدا نگهداری شده است.

تصمیم معماری: استفاده از Webhook به‌جای Polling باعث می‌شود Worker فقط هنگام رسیدن رویداد اجرا شود؛ بنابراین نیازی به سرور دائماً روشن یا حلقهٔ بررسی پیام‌ها نیست. D1 نیز به‌دلیل نیاز به چند جدول مرتبط، فیلتر بر اساس شناسه و تاریخ و تغییر وضعیت رکوردها، انتخاب مناسب‌تری از KV است.

۲ · معماری سامانه

اجزای اصلی و مسیر اجرای یک پیام



شکل ۱ - نمای مفهومی معماری؛ ارسال پاسخ تلگرام از Worker انجام می‌شود و Cron مسیر جداگانهٔ یادآور را فعال می‌کند.

چرخهٔ پردازش پیام

1. تلگرام رویداد را به مسیر `/telegram-webhook` می‌فرستد. درخواست باید از نوع POST باشد و سرآیند محرمانهٔ مخصوص وب‌هوک را حمل کند؛ مقدار نامعتبر با پاسخ 403 رد می‌شود.
2. Worker اندازهٔ بدنه را حداکثر ۱۲۸ کیلوبایت کنترل و JSON را تجزیه می‌کند. سپس شناسهٔ فرستنده با `TELEGRAM_ALLOWED_USER_ID` تطبیق داده می‌شود؛ کاربران غیرمجاز بدون پاسخ رها می‌شوند.
3. شناسهٔ update_id در جدول processed_updates ثبت می‌شود تا تحویل تکراری تلگرام دوباره پردازش نشود. سپس فهرست کارها و تاریخچهٔ کوتاه مکالمه از D1 خوانده می‌شوند.
4. مدل @cf/meta/llama-3.3-70b-instruct-fp8-fast یکی از شش کنش را در قالب JSON پیشنهاد می‌کند. کد JSON را استخراج و ساختار، نوع کنش و شناسهٔ وظیفه را اعتبارسنجی می‌کند؛ در صورت خروجی نامعتبر، یک بار درخواست اصلاحی می‌فرستد.
5. فقط Worker و پس از اعتبارسنجی، عملیات پایگاه‌داده را با Prepared Statement اجرا می‌کند؛ سپس پیام کاربر و پاسخ دستیار در حافظهٔ کوتاه ذخیره و پاسخ فارسی از طریق Telegram Bot API ارسال می‌شود.

اصل ایمنی تصمیم‌گیری: مدل زبانی فقط «پیشنهاد کنش» می‌دهد و مجاز به تغییر مستقیم D1 نیست. شناسهٔ ارسالی مدل باید عدد صحیح و عضو فهرست شناسه‌های واقعی باشد؛ در غیر این صورت عملیات تغییردهنده انجام نمی‌شود.

۳ · لایهٔ ذخیره‌سازی و عملیات

پایگاه‌داده، زمان تهران و استقرار

پایگاه‌دادهٔ Cloudflare D1 از نوع رابطه‌ای و مبتنی بر SQLite است. طرح اولیه در فایل مهاجرت مستقل `migrations/0001_init.sql` تعریف شده و Worker از طریق binding با نام DB به آن دسترسی دارد. تمام پارامترهای ورودی SQL با Prepared Statement متصل می‌شوند تا دادهٔ کاربر به‌عنوان بخشی از دستور SQL تفسیر نشود.

processed_updates

شناسهٔ یکتای پیام تلگرام و زمان پردازش؛ برای جلوگیری از اجرای مجدد Updateهای تکراری. دورهٔ پاک‌سازی تعریف‌شده ۴۸ ساعت است.

conversation_history

نقش و متن پیام‌های کاربر و دستیار به همراه زمان UTC. ایندکس کاربر و شناسهٔ ردیف؛ نگهداری حداکثر ۲۰ ردیف برای هر کاربر.

tasks

متن کار، شناسهٔ کاربر، وضعیت pending/done، روز تقویمی و زمان ایجاد/تکمیل. دو ایندکس برای کاربر-روز و کاربر-وضعیت.

تعریف دقیق «امروز»

سرور ابری الزاماً در منطقهٔ زمانی تهران اجرا نمی‌شود؛ بنابراین تابع `tehranToday()` تاریخ روز را با منطقهٔ زمانی Asia/Tehran محاسبه و به صورت YYYY-MM-DD ذخیره می‌کند. زمان‌های رویداد در ستون‌های زمانی به‌صورت ISO-8601 و UTC نگهداری می‌شوند. این تفکیک مانع وابستگی نتیجه به ساعت یا منطقهٔ زمانی محل اجرای Worker می‌شود.

سلامت و مشاهده‌پذیری

مسیر `/health` با یک پرس‌وجوی `SELECT 1` وضعیت D1 را بررسی می‌کند. در wrangler.jsonc گزینهٔ observability.enabled فعال است.

یادآور روزانه

در تنظیمات Wrangler عبارت `30 6 * * *` ثبت شده است. Cron بر مبنای UTC اجرا می‌شود؛ ۰۶:۳۰ UTC برابر ۱۰:۰۰ تهران است. تابع `scheduled()` وظایف امروز را می‌خواند و فهرست یا پیام خالی‌بودن کارها را ارسال می‌کند.

پیکربندی و نکات استقرار

فایل تنظیمات، binding پایگاه‌داده با نام hermes-mini-db، binding هوش مصنوعی با نام AI و Cron را معرفی می‌کند. نام Worker در پیکربندی فعلی hossdan است. سه مقدار حساس TELEGRAM_BOT_TOKEN، TELEGRAM_WEBHOOK_SECRET و TELEGRAM_ALLOWED_USER_ID باید در محیط امن Cloudflare تعریف شوند؛ در فایل‌های کد ارسالی مقدار واقعی این اسرار دیده نمی‌شود. آدرس زنده و اجرای عملیاتی از روی ZIP قابل تأیید نیست.

نکتهٔ قابلیت: یادآور زمان‌بندی‌شده در کد و تنظیم Cron وجود دارد، اما پیکربندی فعلی تنها برای یک شناسهٔ مجاز طراحی شده است؛ ارسال یادآور انبوه برای چندین کاربر، قابلیت نسخهٔ فعلی نیست.

۴ · ارزیابی اقتصادی و محدودیت‌ها

برآورد هزینه در دو مقیاس

برای قابل‌مقایسه‌بودن دو سناریو، فرض شده هر درخواست به مدل به‌طور متوسط **۱٬۰۰۰ توکن ورودی** و **۱۰۰ توکن خروجی** می‌دهد و مدل در تلاش اول پاسخ معتبر تولید می‌کند. قیمت فعلی مدل انتخاب‌شده در مستندات Cloudflare برابر ۲۶٬۶۶۸ نرون به ازای هر یک میلیون توکن ورودی و ۲۰۴٬۸۰۵ نرون به ازای هر یک میلیون توکن خروجی است؛ بنابراین مصرف فرضی هر پیام حدود ۴۷٫۱۵ نرون می‌شود. مصرف واقعی ممکن است به‌دلیل تاریخچه و فهرست وظایف طولانی‌تر یا تلاش اصلاحی بیشتر باشد.

شاخص	یک کاربر ۱۰ پیام در روز	۱۰٬۰۰۰ کاربر هر نفر ۱ پیام در روز
درخواست Worker در روز	۱۰	۱۰٬۰۰۰
سهمیهٔ رایگان D1	تا ۵ میلیون ردیف خوانده و ۱۰۰هزار ردیف نوشته‌شده در روز	حداقل حدود ۳۰هزار ردیف نوشتن در روز؛ خواندن تابع الگوی کوئری و ایندکس‌هاست
مصرف AI در روز	حدود ۴۷۲ نرون	حدود ۴۷۱٬۴۸۵ نرون
وضعیت سهمیهٔ رایگان AI	کمتر از ۱۰٬۰۰۰ نرون در روز	حدود ۴۶۱٬۴۸۵ نرون بیش از سهمیهٔ رایگان
هزینهٔ تخمینی AI	۰ دلار در محدودهٔ رایگان	حدود ۵٫۰۸ دلار در روز؛ ۱۵۲٫۳۰ دلار در ۳۰ روز
هزینهٔ پایهٔ Worker در پلن پولی	لازم نیست	حداقل ۵ دلار در ماه در صورت نیاز به مصرف بالاتر AI
جمع تقریبی ماهانه	**۰ دلار**	**حدود ۱۵۷٫۳۰ دلار**

تفسیر: برای یک کاربر، مصرف فرضی پایین‌تر از سهمیهٔ روزانهٔ رایگان Workers AI است و تعداد درخواست‌های Worker و استفاده از D1 نیز کوچک خواهد بود. در سناریوی ۱۰هزار کاربر، ۱۰هزار درخواست روزانه هنوز زیر سقف ۱۰۰هزار درخواست رایگان Worker است؛ اما سهمیهٔ ۱۰هزار نرون AI به‌سرعت عبور می‌شود و برای ادامهٔ سرویس باید پلن پولی فعال شود. مبلغ بالا برآورد AI به‌علاوهٔ هزینهٔ پایهٔ ۵ دلاری Worker است و هزینهٔ اضافی احتمالی سایر اجزا را شامل نمی‌شود.

محدودیت‌ها و مسیرهای بهبود

۱) تک‌کاربره‌بودن: مقدار مجاز در کد با یک TELEGRAM_ALLOWED_USER_ID مقایسه می‌شود؛ پس سناریوی ۱۰هزار کاربر فقط پس از طراحی مجدد احراز هویت و توزیع یادآورها ممکن است.

۲) پاک‌سازی پرهزینه: دستور حذف رکوردهای قدیمی processed_updates پس از هر مکالمه اجرا می‌شود، اما برای ستون processed_at ایندکسی در مهاجرت تعریف نشده است. در بار بالا این کار می‌تواند اسکن تکراری جدول ایجاد کند. افزودن ایندکس زمانی و انتقال پاک‌سازی به Cron دوره‌ای پیشنهاد می‌شود.

۳) سقف زمینهٔ مدل: حداکثر ۳۰ وظیفه در زمینهٔ تصمیم‌گیری و ۱۲ ردیف تاریخچه به مدل داده می‌شود؛ در نتیجه فهرست‌های بزرگ‌تر از این حد ممکن است کامل در اختیار مدل یا پاسخ فهرست قرار نگیرند.

۴) قابلیت اطمینان و آزمون: شناسهٔ Update پیش از تکمیل همهٔ مراحل ثبت می‌شود؛ در صورت خطای میانی، تحویل مجدد تلگرام به‌عنوان پیام تکراری کنار گذاشته می‌شود. همچنین در ZIP فایل آزمون Vitest وجود ندارد، هرچند دستور test در package.json تعریف شده است. آزمون سناریوهای ابهام، حذف گروهی، منطقهٔ زمانی و خطای مدل باید اضافه شود.

دربارهٔ تجربهٔ رفع اشکال: ZIP فقط کد و تنظیمات را دربردارد و یادداشت یا تاریخچه‌ای از مشکلات واقعی حین توسعه ندارد؛ بنابراین نمی‌توان با اطمینان گفت توسعه‌دهنده دقیقاً کجا متوقف شده و چگونه آن را رفع کرده است. چالش فنی قابل مشاهده در خود محصول، نامعتبر بودن احتمالی خروجی مدل است که با استخراج JSON، اعتبارسنجی، یک بار تلاش اصلاحی و پاسخ جایگزین مدیریت شده است.

جمع‌بندی: پیاده‌سازی فعلی، هستهٔ مورد انتظار پروژه را در قالب یک Worker رویدادمحور، D1 و Workers AI پوشش می‌دهد و برای نمونهٔ تک‌کاربره مناسب است. نقطهٔ قوت اصلی، جداکردن تصمیم مدل از اجرای عملیات پایگاه‌داده است. برای ارائهٔ نهایی، نمایش زندهٔ وب‌هوک، تنظیم اسرار در Cloudflare و آزمون عملی همهٔ سناریوهای مرزی همچنان باید مستقلاً انجام و مستند شوند.

مبنای هزینه و محدودیت‌ها - مستندات رسمی Cloudflare، مشاهده‌شده در ۵ نوامبر ۲۰۲۶:

[۱] Workers AI Pricing: developers.cloudflare.com/workers-ai/platform/pricing/

[۲] Workers Pricing & Limits: developers.cloudflare.com/workers/platform/pricing/ · developers.cloudflare.com/workers/platform/limits/

[۳] D1 Pricing: developers.cloudflare.com/d1/platform/pricing/

مبنای فنی اصلی: فایل صورت‌مسئلهٔ Cloud Computing Course Project و فایل‌های src/index.js، migrations/0001_init.sql و wrangler.jsonc در ZIP تحویلی. این گزارش تأیید اجرای زنده یا آزمون عملی سامانه نیست.