گزارش پروژه

Hermes-mini

ربات تلگرامی مدیریت کار های روزانه

اراعه دهنده: ملیکا رسولی

استاد راهنما: اقای امیر ابرون

درس: مبانی رایانش ابری

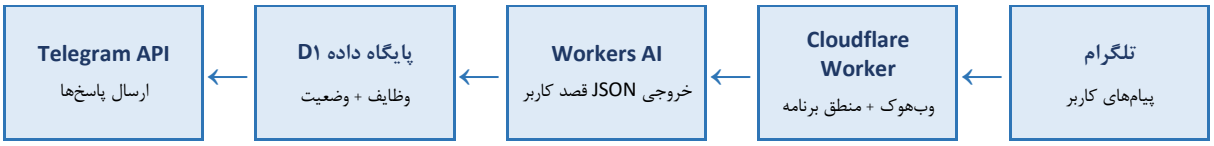
تاریخ: آبان ۱۴۰۵

۱. مرور پروژه

هرمس مینی یک دستیار شخصی مدیریت وظایف به زبان فارسی است که از طریق تلگرام کار می‌کند. کاربر می‌تواند به‌جای استفاده از دستورهای اسلش (/)، وظایفش را به فارسی طبیعی بنویسد. سیستم با استفاده از یک مدل زبانی پیام را تفسیر می‌کند، تفسیر را به مجموعه‌ای محدود از عملیات برنامه نگاشت می‌کند و داده‌های وظایف را به‌صورت پایدار ذخیره می‌کند. پشته فنی پیاده‌سازی‌شده شامل Cloudflare Workers (با TypeScript)، Cloudflare D۱ (بر پایه SQLite)، Wrangler، Workers AI و Telegram Bot API است. Worker مستقرشده در نشانی https://hermes-mini.melikarasoli۳۷.workers.dev در دسترس است.

۲. معماری و تصمیم‌های طراحی

جریان کلی سیستم در شکل ۱ نشان داده شده است:



شکل ۱ – جریان کلی سیستم هرمس مینی

یک Cron Trigger زمان‌بندی‌شده وظایف یادآوری را بررسی می‌کند و D۱ داده‌ها را بین اجراهای مختلف Worker پایدار نگه می‌دارد.

تلگرام پیام‌های دریافتی را از طریق وب‌هوک به Worker می‌فرستد. Worker ابتدا رمز مخفی وب‌هوک را اعتبارسنجی می‌کند و فرستنده را با شناسه کاربری تلگرامِ مجاز (allowlist) مقایسه می‌کند. سپس متن زبان طبیعی را به Workers AI می‌دهد، تفسیر ساختاریافته را اعتبارسنجی می‌کند، عملیات متناظر برنامه را اجرا می‌کند و با Telegram Bot API پاسخ فارسی را برمی‌گرداند. D۱ وظایف و بخش‌های کوچکی از وضعیت برنامه را ذخیره می‌کند. یک Cron Trigger برای بررسی زمان‌بندی‌شده یادآورها پیکربندی شده است.

چرا این معماری؟ وب‌هوک رویدادمحور است و نیازی به اجرای دائمی یک فرایند polling ندارد. Workers مدل اجرای سرورلس ارائه می‌دهند؛ بدون نیاز به مدیریت سرور و با مقیاس‌پذیری بر حسب تقاضا. D۱ به‌جای ذخیره‌ساز کلید-مقدار انتخاب شد، زیرا وظایف فیلدهای ساختاریافته‌ای (وضعیت تکمیل، تاریخ، ساعت و شناسه‌ها) دارند و از کوئری‌های SQL و ایندکس‌ها بهره می‌برند. داده‌های پایدار در D۱ نگهداری می‌شوند، نه در حافظه Worker؛ بنابراین با راه‌اندازی مجدد از بین نمی‌روند و در فراخوانی‌های مختلف در دسترس‌اند.

۳. پیاده‌سازی

Worker و وب‌هوک. Worker نوشته‌شده با TypeScript توسط Wrangler نسخه ۴.۱۵۱.۱ مستقر شده است. نقطه پایانی وب‌هوک تلگرام با هدر secret-token تلگرام محافظت می‌شود. برنامه فقط برای شناسه کاربری تلگرامِ پیکربندی‌شده کار می‌کند و به سایر فرستنده‌ها سرویس نمی‌دهد.

پردازش زبان طبیعی. Workers AI به Worker متصل (bind) شده و برای استفاده از مدل @cf/meta/llama-۳.۳-۷۰b-instruct-fp۸-fast پیکربندی شده است. این مدل درخواست‌های فارسی را به یک ساختار JSON محدود از عملیات تبدیل می‌کند. پیش از اجرای هر عملیات، اعتبارسنجی سمت برنامه انجام می‌شود تا متن دلخواه مدل به‌عنوان دستور اجرایی در نظر گرفته نشود.

عملیات وظایف و تاریخ‌ها. ربات از ایجاد وظیفه با زبان طبیعی، انجام‌شده/لغو انجام وظیفه، فهرست‌کردن، جست‌وجو و پاسخ‌های گفت‌وگویی پشتیبانی می‌کند. مدیریت وظایف «امروز/فردا» بر اساس منطقه زمانی Asia/Tehran انجام می‌شود. هر رکورد وظیفه شامل متن، وضعیت تکمیل، روز، زمان ایجاد، ساعت اختیاری، وضعیت یادآوری و زمان تکمیل است.

پایگاه داده و مایگریشن‌ها. D۱ از SQLite استفاده می‌کند. دو مایگریشن SQL جداگانه وجود دارد: اولی جدول وظایف و ایندکس را می‌سازد و دومی فیلدهای ساعت/یادآوری و یک جدول وضعیت (state) را اضافه می‌کند. مایگریشن‌ها با موفقیت روی پایگاه داده remote و local اعمال شدند.

عملیات و استقرار. Worker روی نشانی زنده workers.dev مستقر شده است. ثبت وب‌هوک تلگرام از طریق یک مسیر راه‌اندازی محافظت‌شده که از داخل خود Worker اجرا شد انجام گرفت، چون دسترسی مستقیم به API تلگرام از شبکه محیط توسعه پایدار نبود. قابلیت Observability در پیکربندی Worker فعال است.

۴. امنیت و پایداری

رمز مخفی وب‌هوک تلگرام به‌عنوان secret در Cloudflare ذخیره شده و در مخزن کد commit نشده است. فایل secretهای توسعه محلی (.dev.vars) از طریق .gitignore کنار گذاشته شده است. توکن ربات و رمز وب‌هوک در محیط production با مدیریت secret ابزار Wrangler پیکربندی شدند. allowlist فرستنده، برنامه را به یک کاربر مجاز محدود می‌کند. خروجی مدل به‌عنوان ورودی نامطمئن در نظر گرفته می‌شود: پیش از هر عملیات پایگاه داده، تجزیه (parse) شده و با ساختار عملیات پشتیبانی‌شده تطبیق داده می‌شود. وضعیت پایدار در D۱ ذخیره می‌شود، نه در حافظه موقت Worker.

۵. تحلیل هزینه و مقیاس‌پذیری

برآوردهای زیر بر اساس محدودیت‌ها و قیمت‌های منتشرشده Cloudflare در زمان نگارش است. مصرف واقعی به تعداد پیام‌ها، توکن‌های ورودی/خروجی مدل، تعداد ردیف‌های خوانده‌شده یا تغییریافته در SQL و میزان فعالیت یادآورها بستگی دارد. فرض شده است که تلگرام از طریق Bot API و بدون سرویس میزبانی پولیِ جداگانه استفاده می‌شود.

خلاصه محدودیت‌ها و قیمت‌ها در جدول ۱ آمده است:

مؤلفه	سهمیه پلن رایگان / مرجع قیمت	تأثیر
Workers	۱۰۰٬۰۰۰ درخواست در روز؛ ۱۰ میلی‌ثانیه CPU برای هر فراخوانی در پلن رایگان. پلن پولی از ۵ دلار در ماه شروع می‌شود و ۱۰ میلیون درخواست در ماه را پیش از هزینه اضافه شامل می‌شود.	ظرفیت درخواست برای یک کاربر به‌راحتی کافی است. با ۱۰٬۰۰۰ کاربر، بسته به میزان فعالیت ممکن است از سقف روزانه پلن رایگان فراتر برود.

مؤلفه	سهمیه پلن رایگان / مرجع قیمت	تأثیر
D۱	۵ میلیون ردیف خوانده‌شده در روز، ۱۰۰٬۰۰۰ ردیف نوشته‌شده در روز و ۵ گیگابایت فضای ذخیره‌سازی کل در پلن رایگان.	رکوردهای کوچک وظایف شخصی هزینه کمی دارند. در ۱۰٬۰۰۰ کاربر، حجم کوئری‌ها و تاریخچه ذخیره‌شده باید اندازه‌گیری شود.
Workers AI	۱۰٬۰۰۰ نورون (Neuron) در روز رایگان؛ بیش از آن ۰٫۰۱۱ دلار به ازای هر ۱۰۰۰ نورون در Workers Paid.	احتمالاً مهم‌ترین هزینه متغیر در مقیاس بالاتر است، چون هر درخواست زبان طبیعی ممکن است مدل را فراخوانی کند.

جدول ۱ – محدودیت‌های پلن رایگان و تأثیر آن‌ها بر هر مؤلفه

سناریوی الف – ۱ کاربر. با استفاده روزانه متوسط، انتظار می‌رود درخواست‌های Worker و عملیات D۱ در محدوده سهمیه رایگان بمانند. تا زمانی که مصرف روزانه Workers AI حداکثر ۱۰٬۰۰۰ نورون باشد، آن هم رایگان است. بنابراین با این فرض‌ها هزینه مورد انتظار پلتفرم ۰ دلار در ماه است. این یک برآورد است، نه تضمین؛ مصرف واقعی نورون‌های هوش مصنوعی باید پایش شود.

سناریوی ب – ۱۰٬۰۰۰ کاربر. اگر هر کاربر روزانه ۱۰ پیام بفرستد، سیستم روزانه حدود ۱۰۰٬۰۰۰ درخواست کاربر دریافت می‌کند (بدون احتساب رویدادهای زمان‌بندی‌شده و تلاش‌های مجدد). این مقدار درست در سقف درخواست روزانه Workers رایگان است و هیچ حاشیه ایمنی باقی نمی‌گذارد. پلن Workers Paid مبنای عملی خواهد بود (حداقل ۵ دلار در ماه)، در حالی که D۱ در صورت کارآمد بودن کوئری‌ها ممکن است در محدوده سهمیه‌های شامل‌شده بماند. هزینه Workers AI بدون اندازه‌گیری مصرف نورون به ازای هر درخواست قابل برآورد دقیق نیست. اگر میانگین مصرف N نورون به ازای هر پیام باشد، مصرف روزانه تقریباً ۱۰۰٬۰۰۰ × N نورون است و هزینه هوش مصنوعی بالاتر از سهمیه روزانه ۱۰٬۰۰۰ نورونی تقریباً برابر است با ۰٫۰۱۱ × (نورون‌های روزانه − ۱۰٬۰۰۰) / ۱۰۰۰ دلار در روز. بنابراین نباید برای ۱۰٬۰۰۰ کاربر استقرار بدون هزینه را وعده داد؛ مصرف مدل و حجم درخواست‌ها باید با تست بار سنجیده و بودجه‌بندی شود.

۶. چالش‌ها و راه‌حل‌ها

اتصال به API تلگرام. در طول توسعه، شبکه محلی نمی‌توانست api.telegram.org را به‌طور پایدار resolve کند یا به آن متصل شود و یک Cloudflare Quick Tunnel نیز اتصالش را از دست داد. به‌جای وابستگی به دستگاه محلی، یک مسیر راه‌اندازی محافظت‌شده روی Worker مستقر شد و از آن برای فراخوانی API متد setWebhook تلگرام از محیط Cloudflare استفاده شد. تلگرام تأیید کرد که وب‌هوک با موفقیت تنظیم شده است.

مدیریت تاریخ و منطقه زمانی. در ابتدا وظایفی که کلمه «فردا» در آن‌ها بود با تاریخ امروز ذخیره می‌شدند. منطق تاریخ وظایف به‌روزرسانی شد تا عبارت‌های تاریخ نسبی فارسی را تشخیص دهد و تاریخ محاسبه‌شده را به تابع درج در پایگاه داده بدهد. محاسبات تاریخ و فهرست امروز/فردا بر اساس منطقه زمانی Asia/Tehran انجام می‌شود. رکوردهای آزمایشی موجود اصلاح شدند و یک پرسش زبان طبیعی درباره «فردا» با موفقیت آزمایش شد.

پیام‌های مایگریشن. Wrangler گاهی پیام «No migrations to apply» نشان می‌داد. این پیام نشان می‌داد که فایل‌های مایگریشن پیش‌تر روی آن محیط پایگاه داده اعمال شده‌اند، نه اینکه مایگریشن شکست خورده باشد. وضعیت مایگریشن remote و local به‌طور جداگانه بررسی شد.

۷. نتیجه‌گیری

هرمس مینی یک برنامه سرورلس کوچک را نشان می‌دهد که اجرای رویدادمحور، ذخیره‌سازی SQL مدیریت‌شده و یک رابط زبانی مبتنی بر هوش مصنوعی را ترکیب می‌کند. نسخه مستقرشده از تعامل زبان طبیعی فارسی برای مدیریت وظایف و ذخیره پایدار رکوردها پشتیبانی می‌کند و در عین حال زیرساخت را ساده و برای بارکاری تک‌کاربره در راستای پلن رایگان Cloudflare نگه می‌دارد. انتظار می‌رود مهم‌ترین محدودیت مقیاس‌پذیری، مصرف استنتاج (inference) هوش مصنوعی باشد و پس از آن حجم درخواست‌های Worker در تعداد کاربران بالاتر. کارهای آینده باید شامل تست بار، پایش مصرف اندازه‌گیری‌شده هوش مصنوعی، بازبینی درخواست‌های مبهم یا مخرب، و حذف مسیر موقت راه‌اندازی وب‌هوک پس از اتمام تنظیمات (در صورت عدم نیاز) باشد.