مستند ارائه‌ی پروژه — hermes-mini

معرفی پروژه

hermes-mini یک ربات تلگرام فارسی برای مدیریت کارهای روزانه است که کاملاً روی پلن رایگان Cloudflare اجرا می شود. کاربر به فارسی آزاد می‌نویسد، مدل زبانی یکی از شش اکشن ثابت را انتخاب می‌کند و ربات فارسی پاسخ می‌دهد.

مقدار	مورد
`https://hermes-mini.sarahmalekipour8112.workers.dev`	آدرس زنده
Workers + D1 + Workers AI + Cron Trigger	پلتفرم
یک فایل ۱۱۷ ،`src/index.ts` آزمون خودکار	کد

نیازمندی‌ها و پوشش آن‌ها

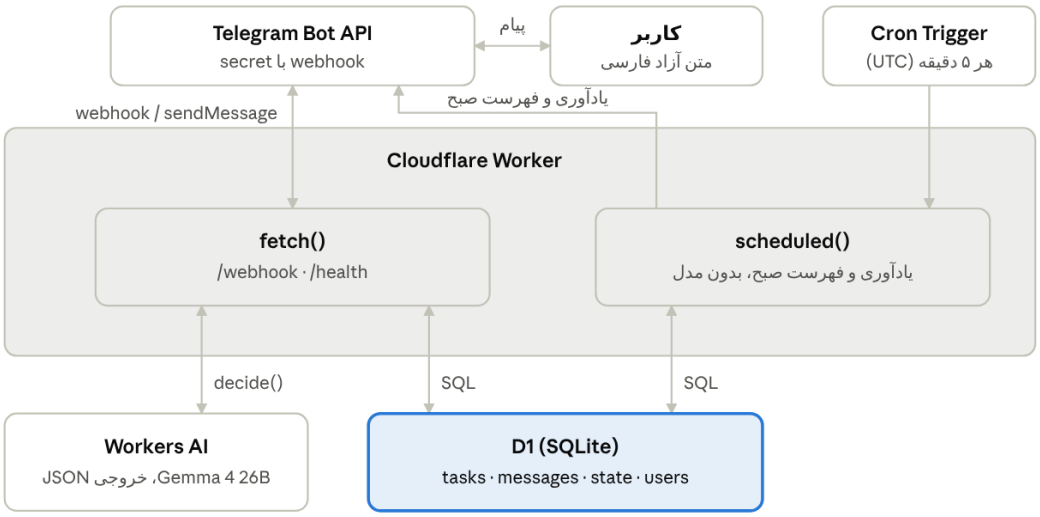
هفت نیازمندی از هشت نیازمندی به‌طور کامل پیاده شده‌اند، به اضافه‌ی بخش امتیازی (یادآوری صبحگاهی).

نیازمندی	پیاده‌سازی
R1 متن آزاد، بدون دستور	همه‌چیز از مدل می‌گذرد؛ دکمه‌ها فقط متن تایپ می‌کنند
R2 شش اکشن ثابت	اکشن جدیدی اضافه نشد؛ تاریخ و دسته فیلد اختیاری‌اند
R3 JSON معتبر، مسیر امن	اعتبارسنجی، یک تلاش مجدد، پاسخ جایگزین
R4 حافظه‌ی گفتگو	۶ پیام آخر به مدل داده می‌شود
R5 تک‌کاربره	فقط کاربرهای تایید شده توسط ادمین می توانند استفاده کنند
R6 webhook با secret	غلط یا خالی ← `403` header
R7 جدا migration ،D1	چهار migration در `migrations/`
R8 پلن رایگان	همه رایگان ،Cron و Workers AI ،D1 ،Workers

معماری و تصمیم‌های اصلی

تلگرام هر پیام را با webhook به یک Cloudflare Worker می‌فرستد؛ Worker بی‌حالت (stateless) است و همه‌ی حالت در D۱ می‌ماند. یک Cron Trigger همان Worker را هر ۵ دقیقه برای یادآوری‌ها صدا می‌زند.

Worker بی‌حالت است؛ همه‌ی حالت در D1 می‌ماند

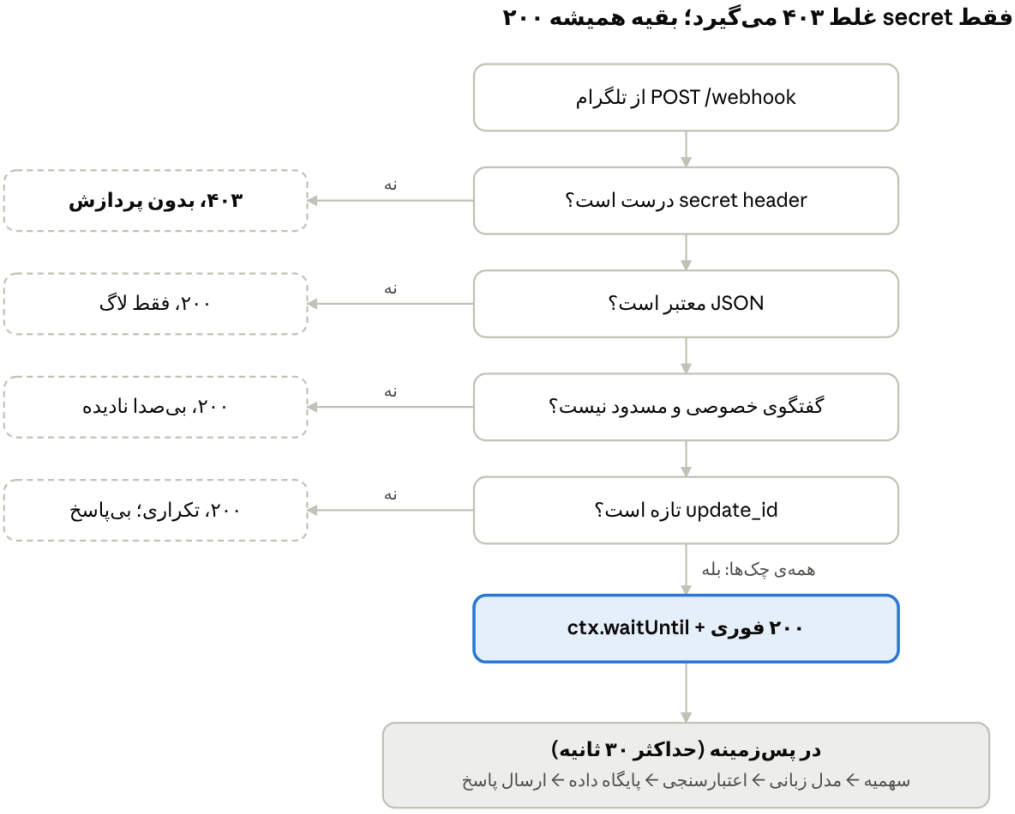


۰۷ بخش معماری

تصمیم	دلیل
Webhook نه polling	Workerفرآیند pollingدائمی ندارد؛ یعنی تأخیر و اجرای بی‌فایده ندارد
Workers (FaaS)	ربات بیش از ۹۹٪ وقت بیکار است؛ سرور برای بیکاری هم هزینه دارد
D1 نه KV	کوئری رابطه‌ای و dedup به سازگاری فوری نیاز دارد
همه‌ی state در D۱	Workerبین درخواست‌ها حافظه ندارد
Gemma 4 26B روی AI Workers	فارسی خوب، خروجی JSON، رایگان و بدون کلید خارجی

مسیر یک پیام

هر پیام از پنج لایه‌ی ارزان به گران می‌گذرد؛ تلگرام همیشه ۲۰۰ می‌گیرد، جز وقتی که secret غلط باشد و ۴۰۳ برمی‌گردد.



همه‌ی ردشدن‌ها پیش از رسیدن به مدل اتفاق می‌افتند؛ فقط پیامی که از هر چهار دروازه بگذرد هزینه‌ی مدل دارد.

لایه‌ی هوش مصنوعی

خروجی مدل هرگز بدون اعتبارسنجی به پایگاه داده نمی‌رسد. مدل فقط تصمیم می‌گیرد؛ اجرای تصمیم و متن تأییدیه از ردیف‌های D۱ ساخته می‌شود، نه از حرف مدل.

- **قرارداد:** مدل یک خط JSON برمی‌گرداند با `day`، `due`، `category`، `refs`، `titles`، `action` و `reply`.
- **مسیر امن:** اعتبارسنجی، یک تلاش مجدد با متن خطا، و بعد پاسخ جایگزین؛ مهلت کل ۲۰ ثانیه.
- **بدون شناسه‌ی واقعی:** مدل فقط شماره‌ی نمایشی فهرست را می‌بیند؛ شماره‌ی بیرون از فهرست و تاریخ گذشته در کد رد می‌شوند، و حذف چندتایی تأیید می‌خواهد.
- **تاریخ:** مدل تاریخ را حساب نمی‌کند، از تقویم ۱۴ روزه‌ی داخل prompt (میلادی، روز هفته، شمسی) برمی‌دارد.

پایگاه داده‌ی D1

پنج جدول همه‌ی حالت را نگه می‌دارند: seen_updates، state، messages، tasks و users. همه‌ی کوئری‌ها با bind.()prepare() است و چهار migration جدا در migrations/ قرار دارد.

تعریف «امروز»: زمان‌ها به UTC ذخیره می‌شوند و «امروز» = ('now', '+۲۱۰ minutes')date. آفست ثابت ۳:۳۰+ درست است چون ایران از ۲۰۲۲ ساعت تابستانی ندارد.

قابلیت‌ها

همه‌ی قابلیت‌ها بدون اکشن جدید ساخته شدند.

- **دسته‌بندی و برنامه‌ریزی:** «پنجشنبه ساعت ۵ عصر ارائه‌ی دانشگاه دارم» یک کار با دسته و زمان می‌سازد؛ کارهای آینده در «برنامه‌های بعدی» می‌آیند.
- **یادآوری:** ۳۰ دقیقه قبل از کار ساعت‌دار، و فهرست صبحگاهی ساعت ۰۸:۰۰ تهران. Cron هر ۵ دقیقه اجرا می‌شود و مدل زبانی را صدا نمی‌زند.
- **دکمه‌ها:** «لیست امروز»، «برنامه‌های بعدی» و «راهنما» فقط متن خودشان را تایپ می‌کنند، پس باز هم از مدل می‌گذرند.
- **ظاهر:** قالب HTML امن (هر متن کاربر escape می‌شود) و پیام خوش‌آمد ثابت برای Start.

خصوصی و کاربرهای تایید شده

ربات خصوصی است: هر کسی در گفتگوی خصوصی با تأیید مدیر از آن استفاده می‌کند.

- **جداسازی داده:** هر کوئری شرط WHERE user_id = ? دارد؛ گروه‌ها و شناسه‌های BLOCKED_USER_IDS نادیده گرفته می‌شوند.
- **سقف مصرف:** سهمیه‌ی رایگان مدل حدود ۴۰۰ پیام در روز برای همه است؛ هر کاربر ۲۰ پیام و همه به جز مدیر با هم ۲۵۰ پیام در روز. بعد از آن پاسخ فارسی ثابت، بدون مدل.
- **در محدودیت پلن رایگان :**حداکثر ۳۰ یادآوری و ۸ فهرست صبحگاهی در هر اجرا، تا زیر سقف ۵۰ درخواست بماند

عملیات، استقرار و امنیت

- **استقرار:** `npm run deploy`؛ migration با `npx wrangler d۱ migrations apply hermes-db --remote`.
- **متغیرهای امنیتی:** TELEGRAM_TOKEN و WEBHOOK_SECRET فقط با wrangler secret put؛ هیچ secretی در مخزن نیست و لاگ‌ها توکن را چاپ نمی‌کنند.
- **پایش:** observability روشن است و لاگ زنده با `npx wrangler tail hermes-mini` دیده می‌شود.
- **امنیت:** کوئری‌های پارامتری (بدون تزریق SQL) و متن کاربر و مدل HTML-escape می‌شود.

چالش‌ها و راه‌حل‌ها

مشکل	راه‌حل
«شماره ۵ رو پاک کن» با سه کار، مدل را به حدس شماره‌ی دیگری وامی‌داشت	اعتبارسنج فقط شکل را چک می‌کند؛ وجود شماره در کد
تلگرام از ایران فیلتر است و تست محلی پاسخ نمی‌فرستاد	بررسی از روی D۱، و تست واقعی پس از استقرار
تحویل وب‌هوک در تلگرام گیر کرده بود	اجرای دوباره‌ی setWebhook
«صبح بخیر» ساعت ۲۱:۲۰ شب رسید	ارسال فقط بین ۰۸:۰۰ تا ۰۸:۵۹
عمومی شدن می‌توانست سهمیه‌ی مدل را تمام کند	سقف هر کاربر و سقف کل، مدیر معاف

آزمون‌ها

۱۱۷ آزمون خودکار در runtime واقعی Workers همه موفق‌اند (`npx vitest run`)؛ مدل و تلگرام mock شده‌اند و D۱ واقعی است. رفتار مدل واقعی هم با `wrangler dev` بررسی شد.

سناریوی دمو و سوالات احتمالی

دموی زنده ۳ دقیقه‌ای، با `wrangler tail` باز در کنار:

۱. پیام خوش‌آمد و دکمه‌ها ← Start
۲. «پنجشنبه ساعت ۵ عصر ارائه‌ی دانشگاه دارم» ← دسته و تاریخ درست
۳. «دومی رو انجام دادم» ← علامت انجام
۴. پیام‌های سخت: «شماره ۹ رو پاک کن»، «همه رو پاک کن» ← نه

۵. curl: `/health` ← `200`، webhook 403 ←without secret

سوال احتمالی	پاسخ کوتاه
چرا همیشه `۲۰۰`؟	تلگرام پاسخ غیر ۲xx را دوباره می‌فرستد؛ فقط secret غلط `۴۰۳` است.
اگر مدل JSON خراب بدهد؟	یک تلاش مجدد، بعد پاسخ جایگزین؛ چیزی در D۱ نوشته نمی‌شود.
مدل می‌تواند کار اشتباه را پاک کند؟	شناسه نمی‌بیند؛ شماره‌ی نامعتبر در کد رد و حذف چندتایی تأیید می‌خواهد.
چرا با R۵ متفاوت است؟	تصمیم آگاهانه؛ جداسازی داده، لیست مسدود و سقف مصرف هدف R۵ را حفظ می‌کنند.
یادآوری دو بار نمی‌رود؟	علامت‌گذاری و خواندن را در `UPDATE … RETURNING` یک کوئری انجام می‌دهد.